

**UNIVERSIDADE DO VALE DO RIO DOS SINOS - UNISINOS**  
**UNIDADE ACADÊMICA DE GRADUAÇÃO**  
**CURSO DE SISTEMAS DE INFORMAÇÃO**

**RAPHAEL BENEDETI**

**INTELIGÊNCIA ARTIFICIAL NO APOIO À TOMADA DE DECISÃO EM**  
**INSTITUIÇÕES BANCÁRIAS**

**Porto Alegre**  
**2024**

RAPHAEL BENEDETI

**INTELIGÊNCIA ARTIFICIAL NO APOIO À TOMADA DE DECISÃO EM  
INSTITUIÇÕES BANCÁRIAS**

Artigo apresentado como requisito parcial  
para obtenção do título de Bacharel em  
Sistemas de Informação, pelo Curso de  
Sistemas de Informação da Universidade  
do Vale do Rio dos Sinos (UNISINOS).

Orientador: Prof. Dr. Vinicius Costa de Souza

Porto Alegre

2024

## INTELIGÊNCIA ARTIFICIAL NO APOIO À TOMADA DE DECISÃO EM INSTITUIÇÕES BANCÁRIAS

Raphael Benedeti<sup>1</sup>

Vinicius Costa de Souza<sup>2</sup>

**Resumo:** Este artigo apresenta um estudo sobre o impacto da inteligência artificial (IA) na tomada de decisões em instituições bancárias. A pesquisa inicia com uma análise histórica do setor bancário, abordando a evolução da inteligência artificial e sua crescente importância. A seguir, explora como a disponibilidade crescente de dados e os avanços tecnológicos têm transformado profundamente as operações financeiras. Para fundamentar a pesquisa, foi utilizado o conjunto de dados “*Credit Score Classification*” do Kaggle. Com base nesse conjunto, foi desenvolvido um projeto prático que aplica diversos modelos de aprendizado de máquina. Esses modelos incluem Árvore de Decisão, Floresta Aleatória, Regressão Logística, K-Nearest Neighbors e Máquina de Vetores de Suporte, todos utilizados para avaliar a classificação da pontuação de crédito. Além da análise quantitativa, o estudo incorpora entrevistas detalhadas com profissionais do setor bancário. Estas entrevistas são essenciais para compreender a aceitação e percepção do uso da IA no setor, capturando as expectativas, experiências e preocupações dos profissionais em relação à implementação e uso da tecnologia. Assim, este estudo oferece uma visão abrangente e detalhada sobre o papel da IA no setor bancário, destaca suas implicações significativas, os desafios enfrentados e as oportunidades emergentes.

**Palavras-chave:** inteligência artificial; aprendizado de máquina; instituição bancária.

**Abstract:** This article presents a study on the impact of artificial intelligence (AI) on decision-making in banking institutions. The research begins with a historical analysis of the banking sector, addressing the evolution of artificial intelligence and its growing importance. It then explores how the increasing availability of data and technological advancements have profoundly transformed financial operations. To support the research, the “*Credit Score Classification*” dataset from Kaggle was used. Based on this dataset, a practical project was developed that applies various machine learning models. These models include Decision Tree, Random Forest, Logistic Regression, K-Nearest Neighbors, and Support Vector Machine, all used to evaluate credit score classification. In addition to the quantitative analysis, the study incorporates detailed interviews with banking professionals. These interviews are essential for understanding the acceptance and perception of AI use in the sector, capturing the expectations, experiences, and concerns of professionals regarding the implementation and use of the technology. Thus, this study offers a comprehensive and detailed view of the role of AI in the banking sector, highlighting its significant implications, the challenges faced, and the emerging opportunities.

**Keywords:** artificial intelligence; machine learning; banking institution.

---

<sup>1</sup> Aluno do curso de Sistemas de Informação da UNISINOS. E-mail: benedeti.raaphael@gmail.com

<sup>2</sup> Professor Doutor do curso de Sistemas de Informação da UNISINOS. E-mail: viniciuscs@unisinos.br

## 1 INTRODUÇÃO

O setor bancário é fundamental para o desenvolvimento econômico de um país, desempenhando um papel crítico na alocação eficiente de recursos financeiros e na facilitação do comércio e investimento, variáveis responsáveis pelo crescimento econômico (Mendonça, 2006). No entanto, a crescente complexidade das operações bancárias (Vieira *et al.*, 2020), aliada ao volume massivo de dados gerados diariamente, cria um desafio significativo para as instituições financeiras no que diz respeito à tomada de decisões estratégicas, gerenciamento de riscos e melhoria da experiência do cliente.

No cenário moderno das instituições bancárias, a crescente disponibilidade de dados e avanços nas áreas de Inteligência Artificial (IA) oferecem oportunidades significativas para aprimorar a eficiência da tomada de decisões. A vasta quantidade de informações geradas nas realizações de cadastros, transações, interações com clientes e *open banking* cria um ambiente propício para aplicação de técnicas avançadas de análise de dados e aprendizado de máquina. De acordo com essa tendência, a Federação Brasileira de Bancos considerou que em 2022 o uso de IA cresceria de 78% para 100% e o uso de *big data* de 74% para 94%, refletindo o compromisso do setor bancário em aproveitar essas tecnologias para melhorar seus serviços e processos (Mulinari; Biagini, 2023).

Diante desse cenário, no qual a geração de dados cresce exponencialmente, estamos testemunhando uma revolução digital que está transformando profundamente a maneira como vivemos, trabalhamos e interagimos com o mundo ao nosso redor. Em 2015 cada pessoa gerou cerca de 1.3 GB (*Gigabyte*) de dados por dia, a previsão é de que em 2025, cada pessoa gere 5,3 GB de dados por dia (Reinsel; Gantz; Rydning, 2017).

Segundo o *International Data Corporation* (Reinsel; Gantz; Rydning, 2017), em 2025 o cenário global de informações crescerá para 163 *zettabyte* (equivalente a um trilhão de GB). Todo esse volume de dados desbloqueará experiências de usuários e abrirá as portas para um novo mundo de oportunidades de negócios.

Nos dias de hoje, a quantidade de dados gerados supera a capacidade de análise dos seres humanos de maneira significativa. Assim, estratégias como o aprendizado de máquina, a análise preditiva e a visualização de dados desempenham

um papel fundamental em descobrir valor em grandes conjuntos de dados, melhorando significativamente a rapidez e a precisão das decisões (Davis, 2019).

Estamos em posição de gerar, em tempo real, uma representação visual dos indicadores internos e essas informações são cruciais para orientar as tomadas de decisões nas instituições, permitindo uma resposta mais ágil e precisa às mudanças constantes (Doerr; Gambacorta; Garralda, 2021).

Conforme mencionado pelo matemático Norbert Wiener em seu artigo “*Some Moral and Technical Consequences of Automation*”, de 1960:

Se usarmos um órgão mecânico para atingir nossos objetivos, em cujo funcionamento não podemos interferir de forma eficaz... é crucial garantir que o propósito colocado na máquina seja realmente o que desejamos (Wiener, 1960, p. 1355) (Tradução nossa).

De fato, é muito importante que as instituições bancárias tomem conhecimento e façam uso adequado das tecnologias disponíveis com o objetivo de melhorar seus processos de tomada de decisão. Contudo, ainda são poucos os trabalhos que investigaram a adoção da IA e seu impacto nas decisões cruciais realizadas pelas instituições financeiras.

Especificamente, há uma lacuna significativa na compreensão de como essa tecnologia está sendo implementada e como pode influenciar as tomadas de decisões essenciais no setor.

Assim, o avanço da IA no setor bancário oferece um potencial transformador. Algoritmos sofisticados permitem prever tendências de mercado com eficácia, facilitando decisões, reduzindo riscos e melhorando a experiência do cliente.

Nesse sentido, explorar o uso da IA nas instituições bancárias é crucial. Compreender sua aplicação eficaz para apoiar decisões estratégicas e operacionais é fundamental para o sucesso em um ambiente competitivo e em constante mudança.

Este trabalho teve como objetivo geral investigar como a inteligência artificial vem sendo utilizada e como ela pode aprimorar os processos de tomada de decisão em instituições bancárias.

Diante desse cenário desafiador e promissor, este artigo avança explorando as dimensões da inteligência artificial no setor bancário. Primeiramente, são revisados estudos e pesquisas relevantes que contextualizam a aplicação dessas tecnologias nas instituições financeiras. Em seguida, são apresentados os fundamentos teóricos que fundamentam a utilização de modelos de aprendizado de máquina, demonstrando

suas capacidades e limitações. Posteriormente, a metodologia adotada é detalhada, combinando abordagens quantitativas e qualitativas para uma análise robusta dos dados. O estudo prático é então conduzido, aplicando técnicas avançadas para a classificação de crédito e revelando conhecimentos valiosos sobre a eficácia desses modelos. Por fim, são discutidas as percepções de especialistas do setor, fornecendo uma visão crítica e informada sobre o impacto da IA na tomada de decisão. Assim, este artigo oferece uma compreensão profunda e integrada dos benefícios e desafios da inteligência artificial nas operações bancárias.

## 2 TRABALHOS RELACIONADOS

A aplicação de IA e aprendizado de máquina no setor bancário tem sido objeto de diversos estudos e pesquisas, destacando-se por sua capacidade de revolucionar processos, melhorar a experiência do cliente e aumentar a eficiência operacional. A seguir, são apresentados alguns dos principais trabalhos que abordam o uso dessas tecnologias em instituições financeiras.

Praveen Donepudi (2017) fez uma análise abrangente e detalhada sobre a aplicação de aprendizado de máquina e inteligência artificial no setor bancário, destacando como essas tecnologias estão sendo empregadas de forma eficaz no *front-end* e no *back-end* das instituições financeiras para aprimorar a experiência do cliente, automatizar processos, reduzir custos operacionais e impulsionar a eficiência interna, evidenciando o impacto positivo e a relevância crescente dessas ferramentas na transformação digital do setor bancário.

No *front-end*, essas tecnologias são empregadas para melhorar a experiência do usuário, através de *chatbots* personalizados e assistentes virtuais controlados por voz, proporcionando soluções de autoatendimento e serviços mais inteligentes em diversas transações. No *back-end*, a inteligência computacional automatiza tarefas, reduzindo custos e aumentando a produtividade. Utiliza dados históricos para personalizar sugestões e gerenciar riscos, melhorando a avaliação da elegibilidade de clientes para empréstimos ou cartões de crédito (Donepudi, 2017).

O autor destaca que a integração de aprendizado de máquina e inteligência artificial nos bancos melhora eficiência, personalização e inovação. Para serem competitivas, as instituições financeiras devem explorar completamente essas ferramentas em um ambiente tecnológico e baseado em dados.

Já Orçun Kaya (2019) apontou o potencial impacto IA no setor bancário, onde apesar dos investimentos globais expressivos de 24 bilhões de dólares em 2018 e das promessas de eficiência e aumento de receita, sua adoção tem sido moderada.

No setor bancário, algoritmos de IA detectam fraudes em tempo real e *chatbots* facilitam a interação com os clientes, enquanto a IA analisa documentos legais e relatórios anuais, impulsionando os consultores automatizados (*robô-advisor*) para gestão de ativos e planejamento financeiro, oferecendo recomendações personalizadas. Apesar do potencial revolucionário da IA para o setor bancário, incluindo eficiência e aumento de receita, desafios significativos surgem em relação às questões regulatórias relacionadas à privacidade de dados e segurança cibernética, destacando a necessidade de transparência e conformidade nas decisões automatizadas para garantir a rastreabilidade completa nos processos bancários (Kaya, 2019).

O autor destaca:

Em um ambiente em que a concorrência no setor bancário é cada vez mais intensa – graças aos prestadores de serviços financeiros orientados por dados, como as start-ups de tecnologia financeira (FinTech) e as grandes empresas tecnológicas que desafiam os modelos de negócio bancários tradicionais – a rápida implementação de tecnologias de IA poderá ser fundamental para que os bancos permaneçam competitivos (Kaya, 2019, p. 8) (Tradução nossa).

Já Mohsin Asad Gill e colaboradores (2023) discutiram a detecção de ataques cibernéticos em instituições financeiras, destacando a importância da segurança cibernética devido ao alto valor das informações mantidas pelos bancos.

O estudo utilizou técnicas de aprendizado de máquina, como Máquinas de Vetores de Suporte, K-Nearest Neighbors e Florestas Aleatórias, para prever e categorizar ataques cibernéticos. Os resultados mostram que o SVM obteve uma precisão de detecção de 99,5%, superando o desempenho dos outros modelos.

Também foi realizada uma revisão da literatura existente sobre ameaças cibernéticas em bancos e destaca a necessidade de estratégias de segurança cibernética personalizadas para proteger os dados financeiros. Além disso, foram apresentados modelos de detecção de fraudes em transações bancárias online, como o uso de redes neurais profundas (DNN) e sistemas especialistas *fuzzy*.

Por fim, o autor discute a importância da detecção de anomalias em redes de dispositivos interconectados que compõem a internet das coisas (IoT) no setor

bancário, ressaltando a relevância do uso de tecnologias emergentes, como *blockchain*, para fortalecer a segurança cibernética. É ressaltada a necessidade crítica de identificar e responder a ameaças cibernéticas em tempo real para garantir a segurança financeira e a importância de investimentos em segurança cibernética por parte dos governos e instituições financeiras.

### **3 FUNDAMENTAÇÃO TEÓRICA**

Nesta seção, são apresentados os pilares teóricos que sustentam a pesquisa. Iniciamos com uma discussão sobre o sistema bancário e sua história, antes de nos aprofundarmos nas inovações proporcionadas pela inteligência artificial e seus algoritmos.

#### **3.1 Sistema Bancário**

Nappi (2017) ressalta que a atividade bancária sustenta a capacidade conjunta de criar moeda e de atuar como intermediária entre os setores industrial e financeiro, concedendo o poder de influenciar o fluxo da economia e impactar todas as demais atividades econômicas. Nesse contexto, ela desempenha um papel crucial na economia atual, dada a sua relevância, a regulação e supervisão das atividades bancárias desempenham um papel fundamental na manutenção da estabilidade financeira.

Segundo March (2014 *apud* Murakami, 2003), a tomada de decisão é como uma jornada onde interpretamos uma ação como uma escolha racional, indicando que as decisões foram bem-sucedidas. Este processo complexo destaca a habilidade de fazer escolhas inteligentes, levando a resultados positivos.

O processo de tomada de decisão no setor financeiro no Brasil experimentou avanços significativos durante os anos 60 e 70, destacados pela automação bancária. Essa inovação trouxe melhorias substanciais para o processo decisório no setor financeiro. Inicialmente, os bancos adotaram grandes computadores para automatizar as operações de apoio, visando acelerar o processamento de um volume crescente de informações produzidas nas agências. Com o apoio do BACEN e a reforma bancária implantada pelo governo militar, os bancos foram incentivados a investir em



equipamentos de informática e a adotar sistemas de apoio à decisão (Fonseca; Meirelles; Diniz, 2010).

A redefinição dos processos de tomada de decisão no setor bancário, baseada em avançados sistemas de apoio à decisão na automação bancária, tem sido notável. Por meio dessa abordagem integrada, os bancos conseguem consolidar diariamente as posições dos clientes, obtendo informações precisas sobre desempenho e lucratividade em diversas transações e cenários econômicos. Esses dados são compartilhados em toda a organização, proporcionando uma visão abrangente que facilita análises profundas e tomadas de decisões informadas. Os sistemas de apoio à decisão não apenas fornecem dados cruciais, mas também oferecem análises fundamentadas, permitindo que os bancos compreendam melhor seu negócio (Fonseca; Meirelles; Diniz, 2010).

Essa perspectiva, mais completa, facilita a definição de estratégias de investimento, a alocação eficiente de recursos, a gestão de riscos e o atendimento personalizado às necessidades dos clientes. Assim, a automação bancária, aliada aos sistemas de apoio à decisão, desempenha um papel central na melhoria contínua dos processos de tomada de decisão, capacitando os bancos a enfrentarem os desafios do ambiente financeiro com assertividade e eficiência (Fonseca; Meirelles; Diniz, 2010).

### **3.2 Inteligência Artificial no Setor Bancário**

O campo dinâmico da Inteligência Artificial tem sido objeto de análise e definição por especialistas altamente qualificados. O grupo de especialistas de alto nível em inteligência artificial (AI HLEG, 2019) consolidou seus conhecimentos e entendimentos para formular uma definição de IA:

Sistemas de inteligência artificial são sistemas de software (e possivelmente também de hardware) projetados por humanos, que, dado um objetivo complexo, agem na dimensão física ou digital ao perceberem seu ambiente por meio da aquisição de dados, interpretando os dados coletados estruturados ou não estruturados, raciocinando sobre o conhecimento ou processando as informações derivadas desses dados e decidindo a melhor ação a ser tomada para alcançar o objetivo fornecido. Sistemas de IA podem usar regras simbólicas ou aprender um modelo numérico, e podem adaptar seu comportamento analisando como o ambiente é afetado por suas ações anteriores. Como disciplina científica, a IA inclui várias abordagens e técnicas, como machine learning, machine reasoning e robotics. (AI HLEG, 2019, p.6) (Tradução nossa).

A inteligência artificial tem tido um impacto significativo no setor bancário, permitindo que as instituições financeiras automatizem seus processos e melhorem a eficiência operacional. A aplicação de tecnologias avançadas de aprendizado de máquina e análise de dados têm permitido que os bancos coletem informações sobre seus clientes, como perfil de trabalho, renda, detalhes pessoais e histórico de crédito, para oferecer serviços bancários personalizados e soluções em tempo real (Vedapradha; Hariharan, 2018).

De acordo com Vedapradha e Hariharan (2018), o setor bancário está utilizando a inteligência artificial para diversas finalidades, tais como:

- Combate à lavagem de dinheiro e fraudes financeiras: Detecção de atividades suspeitas e transações fraudulentas, assegurando conformidade regulatória e minimizando riscos de penalidades;
- Assistentes virtuais para atendimento ao cliente: Respostas instantâneas para perguntas comuns, auxiliam na navegação online e fornecem suporte técnico, aprimorando o serviço ao cliente dos bancos e a experiência do usuário.
- Melhorando a eficiência operacional: Redução de custos e tempo em processos como abertura de contas e avaliação de crédito. Isso agiliza operações, reduzindo tempo de espera e aumentando a satisfação do cliente.

Além disso, a qualidade das decisões em todos os níveis de gestão está sendo aprimorada, evitando erros e contribuindo para uma tomada de decisão mais robusta e informada, fundamental para o sucesso no ambiente competitivo atual (Vedapradha; Hariharan, 2018).

Dessa forma, a inteligência artificial no setor bancário continua a transformando a indústria, proporcionando um patamar mais elevado de valor aos clientes, reduzindo riscos e ampliando oportunidades, como os motores financeiros da nossa economia moderna (Puri, 2022).

### **3.3 Aprendizado de Máquina**

É uma disciplina dentro do campo da inteligência artificial que se concentra na capacidade dos sistemas de aprender e melhorar com a experiência, sem serem explicitamente programados. Ele opera através da utilização de algoritmos e técnicas estatísticas para identificar padrões e conhecimento nos dados, capacitando os

sistemas a fazerem previsões ou tomar decisões com base nesses padrões identificados (Da Silva, 2023).

Existem diversos métodos empregados nessa tecnologia para a construção de modelos estatísticos preditivos. Entre esses métodos, estão inclusas técnicas como: Árvore de Decisão (*Decision Trees*), Floresta Aleatória (*Random Forest*), Regressão Logística (*Logistic Regression*), Vizinhos Mais Próximos (*K-Nearest Neighbors* - KNN) e Máquina de Vetores de Suporte (*Support Vector Machines* – SVM entre outros (Da Silva, 2023).

### 3.3.1 Árvore de Decisão

A Árvore de Decisão, de classificação supervisionada, é criada com base na estrutura de árvore clássica, com raízes, nós (onde ocorrem divisões), ramos e folhas. Na representação de uma Árvore de Decisão, os nós são circulares, conectados por segmentos que representam os ramos. O processo de agrupamento de dados é orientado pelos valores dos atributos fornecidos, sendo a construção da árvore realizada a partir de dados previamente classificados. A divisão em classes é determinada pelas características que melhor segmentam os dados, com os itens sendo divididos de acordo com os valores dessas características. Essa divisão é aplicada recursivamente a cada subconjunto de dados até que todos os itens no subconjunto compartilhem a mesma classe, concluindo assim o processo (Ali, 2017).

### 3.3.2 Floresta Aleatória (RF)

As Florestas Aleatórias, consistem na combinação de previsões de múltiplas árvores de decisão, resultando em uma resposta única. Essa abordagem proporciona um melhor desempenho em relação ao uso individual de cada árvore do modelo, devido à redução de variância, capturando assim relações complexas entre as variáveis e produzindo resultados mais robustos e precisos. Aprimorada em várias aplicações práticas, essa abordagem se revela como uma tática eficaz na elaboração de modelos preditivos mais desenvolvidos. Oferece uma melhoria em relação às árvores de decisão, que cria múltiplas árvores independentes e reduz a dependência entre elas, aumentando assim a diversidade das previsões (Da Silva, 2023).

### 3.3.3 Regressão Logística

A Regressão Logística é um método estatístico aplicado para obter resultados binários, frequentemente utilizada em problemas de classificação binária. Sua popularidade resulta de sua simplicidade e da facilidade de interpretação dos resultados, tornando uma escolha comum para problemas desse tipo. No entanto, é fundamental considerar que a presença de correlação entre as variáveis independentes deve ser minimizada ou eliminada, conforme destacado por Stanley e Hosmer (2000, *apud* Mota, 2022).

### 3.3.4 Vizinhos Mais Próximos (KNN)

Os algoritmos fundamentados em Vizinhos Próximos representam uma das abordagens mais simples na área da classificação, cuja operação básica consiste em memorizar um conjunto de dados de treinamento e, posteriormente, prever a classe de um novo ponto com base na classe dos vizinhos mais próximos desse ponto. Essencialmente, essa técnica parte do pressuposto de que pontos próximos tendem a pertencer à mesma categoria, facilitando a atribuição de classes. A medida de distância mais utilizada na maioria dos algoritmos baseados em KNN é a distância euclidiana, que é a distância em linha reta entre elementos. Uma vantagem significativa desses algoritmos é que não requerem ajuste de parâmetros durante o treinamento, simplificando assim o processo de modelagem (Fontana, 2020).

### 3.3.5 Máquina de Vetores de Suporte (SVM)

A SVM é um algoritmo de aprendizado de máquina que se baseia no princípio do aprendizado estrutural de risco. Ela busca encontrar o hiperplano de separação que maximize a margem entre classes, resultando em modelos robustos e capazes de desenvolver bem para novos dados. Graças a essa capacidade, a SVM é altamente eficaz mesmo em conjuntos de dados de alta dimensionalidade e em casos em que as classes não são linearmente separáveis. Devido a essa versatilidade e poder, ela se destaca como ferramenta essencial em uma variedade de aplicações de aprendizado supervisionado (Shawe-Taylor; Sun, 2011).

3.4 Métricas de Avaliação

Após a aplicação dos modelos aos dados, é essencial avaliar seu desempenho preditivo utilizando métricas específicas (Stelzer, 2019). Essas métricas desempenham um papel crucial na análise precisa dos resultados do algoritmo, fornecendo uma compreensão detalhada de sua eficácia e desempenho.

Neste contexto, as métricas de avaliação utilizadas nesse trabalho incluem a matriz de confusão, precisão (*precision*), revocação (*recall*), *F1-score* e acurácia (*accuracy*).

3.4.1 Matriz da Confusão

Conforme destacado por Da Silva (2023) uma matriz de confusão é uma representação tabular que resume os resultados das previsões feitas por um modelo em relação aos valores reais das classes em um conjunto de dados. Esta matriz proporciona uma análise sistemática da performance do modelo ao distinguir entre previsões corretas (verdadeiros positivos e verdadeiros negativos) e previsões incorretas (falsos positivos e falsos negativos).

Quadro 1: Matriz de Confusão

		Valor Previsto	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Fonte: Elaborado pelo autor.

### 3.4.2 Precisão

A precisão indica o número total de previsões especificadas como positivas que são atribuídas corretamente e é definida como a relação entre o número de observações positivas previstas corretamente e o número total de observações previstas como positivas. Essa métrica pode ser calculada da seguinte maneira (Mota, 2022):

Equação 1: Precisão

$$Precisão = \frac{VP}{VP + FP}$$

Fonte: Mota (2022)

### 3.4.3 Revocação

A revocação é o número total de casos positivos reais que foram previstos corretamente e é calculada como a proporção entre o número de observações positivas corretamente previstas e o número total de observações positivas, e pode ser expressa da seguinte maneira (Mota, 2022):

Equação 2: Revocação

$$Revocação = \frac{VP}{VP + FN}$$

Fonte: Mota (2022)

### 3.4.4 F1 – Score

A métrica F1 é calculada como a média harmônica entre as métricas de precisão e revocação, e pode ser expressa da seguinte forma (Mota, 2022):

Equação 3: F1- Score

$$F1 = 2 * \frac{Precisão * Revocação}{Precisão + Revocação}$$

Fonte: Mota (2022)

### 3.4.5 Acurácia

A Acurácia é uma métrica que determina a proporção de observações corretamente previstas em relação ao total da amostra. Pode ser calculada da seguinte maneira (Mota, 2022):

Equação 4: Acurácia

$$Acurácia = \frac{(VP + VN)}{(VP + FP + VN + FN)}$$

Fonte: Mota (2022)

## 4 METODOLOGIA

O delineamento da pesquisa explora a abordagem metodológica adotada pelo pesquisador, detalhando os métodos e procedimentos a serem empregados na condução da pesquisa (Azevedo; Machado; Silva, 2011). Neste contexto, foi adotada uma abordagem metodológica ampla, combinando métodos quantitativos e qualitativos de pesquisa exploratória.

Conforme Richardson (2008 *apud* Paschoarelli; Medola; Bonfim, 2015), a pesquisa quantitativa foca na coleta e análise de dados numéricos, utilizando instrumentos estatísticos, enquanto a pesquisa qualitativa busca compreender os entendimentos dos participantes sobre a situação-problema em estudo (Mendonça, 2014). Na pesquisa exploratória, Köche (1997, *apud* Mendonça, 2014) sugere que o objetivo é adaptar o pesquisador com o objeto de estudo e identificar as características essenciais das variáveis.

Assim, participaram do estudo um grupo de profissionais com experiência em instituições bancárias e foi utilizada uma base de dados pública do setor bancário disponível no *Kaggle* sob o título "*Credit score classification*" (Paris, 2022).

A coleta de dados dos profissionais do setor bancário foi realizada por meio de um questionário. De acordo com Lakatos e Marconi (2009, *apud* Azevedo; Machado; Silva, 2011), trata-se de um método de coleta de dados composto por uma série de perguntas organizadas para serem respondidas por escrito e sem a presença do entrevistador.

Para o trabalho com a base de dados pública do setor financeiro, foi utilizada a plataforma gratuita *Kaggle*, adquirida pela Google em 2017 (Vassalo, 2021), conhecida por seu papel central em ciência de dados e aprendizado de máquina.

A metodologia selecionada para a análise de dados neste projeto, reúne a aplicação de técnicas qualitativas de análise de conteúdo e procedimentos quantitativos para a análise estatística. Segundo Dencker e Da Viá (2001, *apud* Azevedo; Machado; Silva, 2011) a análise de conteúdo consiste em categorizar elementos textuais ou comunicativos para descobrir padrões e significados. A análise estatística, conforme destacado por Kerlinger (1980, *apud* Azevedo; Machado; Silva, 2011), é o método para analisar dados quantitativos, visando resumir informações ou considerar relações hipotéticas entre variáveis, auxiliando os pesquisadores na interpretação dessas informações e na busca por significado nos conjuntos de dados.

## 5 ESTUDO PRÁTICO

Esta seção apresenta o estudo prático de análise de uma base de dados pública do setor bancário para apoio a tomada de decisão baseado em aprendizado de máquina.

### 5.1 Apresentação dos Dados

A base de dados "*Credit score classification*" (Paris, 2022) possui informações detalhadas sobre o histórico de crédito de clientes de uma instituição financeira composta por 28 colunas, incluindo uma variedade de tipos de dados, incluindo texto, datas, números inteiros e decimais.

Dentre as várias colunas deste conjunto de dados, a mais crucial é o "*Credit\_Score*". Essa coluna representa a pontuação do cliente, classificada como boa, regular ou ruim, o que a torna um elemento fundamental para análise e previsão dentro do contexto em questão. No anexo A, é possível encontrar uma visão detalhada das colunas da base de dados.

Essa base de dados, disponível em um arquivo CSV, separado por vírgula, possui 100.000 (cem mil) registros e durante a etapa de preparação dos dados, foi conduzida uma cuidadosa limpeza visando eliminar variáveis consideradas desnecessárias para o modelo em construção. Neste processo, os registros contendo



valores discrepantes, conhecidos como *outliers*, foram removidos, totalizando a exclusão de 16.935 registros, enquanto os valores nulos foram substituídos pela mediana, a fim de preservar a integridade e relevância dos dados para a variável em questão.

## 5.2 Implementação

O estudo prático foi conduzido em um ambiente *Docker* na versão 4.27.2, uma plataforma de virtualização que simplifica a criação e execução de aplicativos em contêineres. Para a implementação, *Python* 3.11.6 foi escolhido como a linguagem principal, enquanto o *Jupyter Lab* na versão 4.2.2 serviu como a ferramenta de desenvolvimento *web*. Todos os algoritmos de aprendizado de máquina foram construídos utilizando a biblioteca principal *scikit-learn* na versão 1.5.0.

O código de aprendizado de máquina<sup>3</sup> foi desenvolvido e executado em um *notebook* Lenovo Ideapad S145, equipado com um processador Intel i7-1065G7, 20 GB de memória RAM DDR4, armazenamento SSD de 256 GB e um HD de 500 GB. O sistema operacional utilizado foi o *Microsoft Windows 11 Home*, na arquitetura de 64 bits.

## 5.3 Resultados

A apresentação dos resultados a seguir está organizada de acordo com as metodologias aplicadas, seguida pela comparação entre elas para determinar qual alcançou o melhor resultado de classificação.

O processo de desenvolvimento do modelo de classificação teve início com a divisão do conjunto de dados entre treino e teste do modelo, em seguida foi realizado a normalização das variáveis para que a distribuição de cada variável tenha média 0 e desvio padrão igual a 1.

Raschka e Mirjalili (2017) enfatizam a importância de dividir os dados em conjuntos de treinamento e teste para avaliar a capacidade do modelo de prever e generalizar para novos dados. As proporções comuns incluem 60:40, 70:30 ou 80:20, aumentando o conjunto de treinamento à medida que o número de observações cresce, permitindo um aprendizado mais robusto e uma melhor generalização.

---

<sup>3</sup> Disponível em: <https://github.com/raphaelbenedeti/credit-score-prediction>

A divisão entre os conjuntos de treino e teste foi estruturada de forma a alocar 80% dos dados (66.452 registros) para o treinamento do modelo, enquanto os 20% restantes (16.613 registros) foram reservados para a avaliação da eficácia do modelo.

Os resultados obtidos são apresentados através das matrizes de confusão dos algoritmos utilizados com métricas de avaliação, a porcentagem da classe com maior e menor precisão, além de uma tabela consolidada contendo os valores de precisão, revocação, F1-score e acurácia.

Tabela 1 Matriz de confusão do teste para o modelo Árvore de Decisão com métricas de avaliação

		Prevista			Precisão	Revocação	F1-Score
		Bom	Regular	Ruim			
Real	Classificação do cliente						
	Bom	1854	1017	125	61%	62%	61%
	Regular	1037	6364	1433	73%	72%	72%
	Ruim	151	1383	3249	68%	68%	68%

Fonte: Elaborado pelo autor.

Os dados da Tabela 1 demonstram a notável precisão do modelo na classificação dos clientes rotulados como Regular, com uma assertividade de 6.364 de 8.764 registros, resultando em uma taxa de precisão de 73%. No entanto, sua capacidade de identificar os clientes classificados como Bom foi menor, com uma assertividade de 1.854 de 3.002 resultados, o que corresponde a uma precisão de 61%.

Tabela 2 Matriz de confusão do teste para o modelo Floresta Aleatória com métricas de avaliação

		Prevista			Precisão	Revocação	F1-Score
		Bom	Regular	Ruim			
Real	Classificação do cliente						
	Bom	2198	789	9	74%	73%	74%
	Regular	681	7127	1026	81%	81%	81%
	Ruim	91	880	3812	79%	80%	79%

Fonte: Elaborado pelo autor.

Analisando os dados da Tabela 2, é possível observar a alta precisão do modelo na classificação dos clientes designados como Regular, com 7.127 de 8.796 registros corretos, o que resulta em uma taxa de precisão de 81%. Entretanto, sua capacidade de identificar os clientes classificados como Bom foi menor, com 2.198 de 2.970 resultados corretos, correspondendo a uma precisão de 74%.

Tabela 3 Matriz de confusão do teste para o modelo Regressão Logística com métricas de avaliação

		Prevista			Precisão	Revocação	F1-Score
		Bom	Regular	Ruim			
Real	Bom	1333	1629	34	58%	44%	50%
	Regular	740	6885	1209	65%	78%	71%
	Ruim	219	2056	2508	67%	52%	59%

Fonte: Elaborado pelo autor.

Os dados contidos na Tabela 3 revelam a notável precisão do modelo ao classificar os clientes designados como Ruim, com uma taxa de acerto de 67%, o que equivale a 2.508 acertos de um total de 3.751 registros. No entanto, sua precisão na identificação dos clientes classificados como Bom foi menor, com uma taxa de acerto de 58%, representando 1.333 acertos de 2.292 registros.

Tabela 4 Matriz de confusão do teste para o modelo Vizinhos Mais Próximos com métricas de avaliação

		Prevista			Precisão	Revocação	F1-Score
		Bom	Regular	Ruim			
Real	Bom	1860	1025	111	54%	62%	58%
	Regular	1247	6670	917	70%	76%	72%
	Ruim	358	1892	2533	71%	53%	61%

Fonte: Elaborado pelo autor.

Analisando os dados da Tabela 4, é possível constatar a alta precisão do modelo na classificação dos clientes designados como Ruim, com uma taxa de acerto de 71%, o que equivale a 2.533 acertos de um total de 3.561 registros. No entanto, sua precisão na identificação dos clientes classificados como Bom foi menor, com uma taxa de acerto de 54%, representando 1.860 acertos em 3.465 registros.

Tabela 5 Matriz de confusão do teste para o modelo Máquina de Vetores de Suporte com métricas de avaliação

		Prevista			Precisão	Revocação	F1-Score
	Classificação do cliente	Bom	Regular	Ruim			
Real	Bom	1963	1010	23	55%	66%	60%
	Regular	1160	6665	1019	74%	75%	74%
	Ruim	440	1367	2976	74%	62%	68%

Fonte: Elaborado pelo autor.

Com base nos dados apresentados na Tabela 5, é evidente a impressionante precisão do modelo para categorizar os clientes como Ruim e Regular, alcançamos uma precisão de 74%, resultando em 2.976 previsões corretas de um total de 4.018 e 6.665 previsões corretas de um total de 9.042 registros, respectivamente. No entanto, a capacidade do modelo em identificar os clientes classificados como Bom foi menor, com uma precisão de 55%, resultando em 1.963 acertos de 3.563 registros.

Tabela 6 Métricas de todos os modelos utilizados.

Modelo	Precisão	Revocação	F1 - Score	Acurácia
Árvore de Decisão	67%	67%	67%	69%
Floresta Aleatória	78%	78%	78%	79%
Regressão Logística	63%	58%	60%	65%
Vizinhos Mais Próximo	65%	64%	64%	67%
Máquina de Vetores de Suporte	68%	68%	67%	70%

Fonte: Elaborado pelo autor.

## 5.4 Discussão

A Tabela 6 apresenta uma comparação das métricas de avaliação de todos os modelos utilizados no estudo. Estas métricas incluem precisão, revocação, F1-score e acurácia, proporcionando uma visão clara do desempenho relativo de cada modelo. Através desta comparação, é possível identificar qual modelo ofereceu os melhores resultados em termos de classificação de crédito, destacando as suas capacidades e limitações em diferentes cenários.

Observando os resultados apresentados, todos os modelos apresentaram um desempenho notável na tarefa de classificação de clientes por classes, evidenciando uma consistência notável em seus resultados. Eles alcançaram uma média de métricas superior a 69%, o que valida sua eficácia e confiabilidade no processo de categorização dos clientes.

A identificação preliminar de potenciais clientes com baixa pontuação de crédito desempenha um papel crucial na gestão da inadimplência em operações de concessão de crédito, sendo essencial para a saúde financeira de uma instituição bancária. Pesquisas dedicadas a esse tema são de grande importância para refinamento dos modelos de aprendizado de máquina no setor financeiro. Estes estudos abrangem a análise comparativa de diversos modelos, visando identificar o mais adequado às circunstâncias específicas, o que contribui para o contínuo avanço e aprimoramento de modelos cada vez mais precisos.

É essencial enfatizar que todos os modelos desenvolvidos obtiveram resultados excelentes na classificação das classes. No entanto, o modelo de Floresta Aleatória teve destaque de forma significativa ao alcançar o melhor desempenho ao considerar todas as três classes. Esta distinção foi o ponto crucial entre os modelos, já que a Árvore de Decisão, Regressão Logística, KNN e SVM apresentaram resultados similares, com uma ligeira vantagem geral para o SVM, e uma desvantagem geral para o modelo de Regressão Logística.

## 6 PESQUISAS COM ESPECIALISTAS

Esta seção apresenta a pesquisa realizada com o objetivo de explorar perspectivas e conhecimentos relevantes sobre o uso de IA para processos de tomada

de decisão e a experiência do usuário no setor bancário, visando aprimorar estratégias de desenvolvimento e inovação.

### **6.1 Participantes**

A pesquisa contou com 15 participantes com idade média de 41 anos, predominando aqueles com mais de 30 anos. A composição de gênero foi de 60% masculino e 40% feminino. A maioria dos participantes possui formação acadêmica avançada, como Ensino Superior, Pós-Graduação ou Mestrado, sendo a maioria formado em Administração.

Os participantes (ver Apêndice B) possuem experiência no setor bancário variando de 1 a mais de 20 anos, sendo que 33,3% representam a maioria com mais de duas décadas de atuação. Eles trabalham em diversos departamentos, como operações, risco de crédito, cobrança, atendimento e empréstimo, entre outros. Essa diversidade proporciona uma visão ampla sobre práticas e desafios na tomada de decisões no setor.

### **6.2 Procedimento**

Para a realização da pesquisa, a plataforma *online Google Forms* foi acionada devido à sua facilidade de uso e eficiência na coleta de dados. Foram 17 perguntas, divididas entre sete de múltipla escolha e dez dissertativas, a fim de obter uma visão abrangente das percepções dos participantes. Obtivemos 15 respostas ao questionário, conforme apresentado no Apêndice A, o que nos proporcionou uma amostra significativa para a análise.

### **6.3 Resultados**

Os resultados revelam que 53,3% dos profissionais bancários, representando a maioria, fundamentam suas decisões em uma combinação de experiência profissional e sistemas automatizados, refletindo a importância de integrar o conhecimento humano com tecnologias avançadas.

Os participantes expressaram expectativas positivas em relação ao uso de IA, destacando benefícios como maiores. Eles acreditam que a IA melhorará a

experiência do cliente nos serviços bancários ao automatizar processos, personalizar atendimentos, detectar fraudes e otimizar tempo e trabalho. Embora alguns considerem que a implementação inicial possa ter desafios, há consenso de que, a longo prazo, o impacto será amplamente positivo, atendendo às crescentes demandas dos clientes. A visão otimista dos participantes sugere que a IA pode aumentar significativamente a eficiência operacional e a precisão nas decisões bancárias. Eles reforçam que a maioria das áreas, se não todas, terão benefícios ao adotar o uso de IA.

Quanto ao uso de Inteligência Artificial para prever o *score* de crédito de um cliente, os participantes expressaram uma opinião amplamente favorável. Eles destacaram o potencial dessa abordagem e a consideraram uma ferramenta valiosa. 33,3% dos participantes concordaram totalmente, acreditando que pode ser uma ferramenta valiosa, enquanto 67,3% concordaram, vendo potencial nessa abordagem. A unanimidade nas respostas reflete uma confiança geral na eficácia da IA para tomar decisões financeiras mais precisas e informadas, beneficiando tanto as instituições bancárias quanto os clientes.

Os participantes destacaram diversas vantagens da IA para prever o *score* de crédito de um cliente, como agilidade na concessão de empréstimos, melhor cálculo de preço e risco, maior segurança, e a capacidade de analisar grandes quantidades de variáveis internas e externas do cliente. Eles também mencionaram a identificação de potenciais inadimplentes e fraudulentos, a precisão e rapidez nas análises, e a contribuição para decisões de crédito, especialmente quando o cliente já possui um relacionamento com a instituição.

Sobre o nível de precisão aceitável para a tomada de decisão baseada em Inteligência Artificial, 60% dos participantes consideraram aceitável uma alta precisão, entre 90% e 100%, enquanto 40% aceitam uma precisão moderada, entre 75% e 89%. Isso demonstra uma preferência geral por alta precisão nas previsões, reforçando a confiança na capacidade da IA de fornecer informações confiáveis para decisões financeiras críticas.

Apesar do otimismo em relação ao uso da IA para a tomada de decisões no setor bancário, os participantes expressaram várias preocupações significativas. Embora alguns acreditem que a IA possa ser eficaz, especialmente quando alimentada com dados de qualidade e confiáveis, há um consenso de que a supervisão humana ainda é essencial. Preocupações comuns incluem a privacidade

dos dados, possíveis vieses nos algoritmos, e a confiança exagerada na tecnologia. Muitos participantes destacaram a necessidade de uma análise mais pessoal em alguns casos e o perigo de depender exclusivamente da IA sem validações humanas. A combinação da IA com a experiência e supervisão humanas é considerada crucial para o sucesso e a segurança no setor bancário.

Os resultados apresentados neste capítulo oferecem uma análise abrangente das respostas dos participantes sobre o uso de IA no setor bancário. Para facilitar a visualização e compreensão das respostas, os dados detalhados estão disponíveis em formato de gráfico nos Apêndices C, D e E, nomeados respectivamente "Dados Demográficos dos Entrevistados", "Características de Atuação dos Participantes" e "Percepções e Benefícios da IA no Setor Bancário".

## **6.4 Discussão**

Os resultados do questionário indicam uma aceitação geral da IA como uma ferramenta precisa e valiosa para a tomada de decisão no setor bancário. No entanto, a necessidade de supervisão humana contínua foi destacada, mostrando que, embora a IA seja eficaz, a interação humana é essencial para garantir decisões precisas e contextualizadas. Isso sugere que a IA deve ser vista como um complemento às habilidades humanas, e não como um substituto total.

As preocupações levantadas sobre a dependência excessiva da tecnologia e a confiança exagerada nas ferramentas de IA e os dados utilizados destacam a necessidade de uma abordagem equilibrada. Os profissionais bancários valorizam o julgamento humano, especialmente em situações complexas, o que indica que a implementação da IA deve ser feita de forma cuidadosa e transparente. A combinação de IA e intervenção humana pode maximizar os benefícios da tecnologia enquanto minimiza os riscos associados à sua utilização.

Por fim, a diversidade das áreas de atuação dos participantes sugere que a aplicação da IA no setor bancário deve ser adaptada às necessidades específicas de cada departamento. Treinamento contínuo e governança rigorosa são essenciais para garantir que a IA seja utilizada de maneira ética e responsável. Assim, a IA pode transformar a tomada de decisão bancária, desde que implementada com uma abordagem que valorize tanto a inovação tecnológica quanto a expertise humana.



## 7 CONCLUSÃO

O estudo buscou avaliar o impacto da IA na tomada de decisão em instituições bancárias, destacando sua aplicação e eficácia. A análise revelou que a IA, especialmente através de técnicas de aprendizado de máquina, oferece ferramentas poderosas para melhorar a precisão e a eficiência nas decisões financeiras.

A investigação incluiu uma avaliação dos principais desafios e oportunidades associados à adoção da IA no setor bancário. Entre os desafios, destacam-se questões relacionadas à privacidade de dados, segurança cibernética e a necessidade de transparência nos processos automatizados. No entanto, as oportunidades superaram esses desafios, mostrando que a IA pode aumentar a eficiência operacional, reduzir custos e melhorar a experiência do cliente.

Os resultados do estudo prático confirmaram a eficácia dos modelos de aprendizado de máquina na classificação da pontuação de crédito. Modelos como Floresta Aleatória e Máquina de Vetores de Suporte destacaram pela sua alta precisão e capacidade de generalização. Estes modelos mostraram particularmente eficazes na identificação de padrões complexos nos dados, o que é crucial para a tomada de decisões informadas em um ambiente bancário dinâmico.

A pesquisa também destacou a importância da colaboração entre humanos e sistemas de IA. Embora a IA forneça uma base sólida para a tomada de decisões, a supervisão humana continua sendo essencial para interpretar os resultados no contexto adequado e tomar decisões finais. Esta abordagem híbrida garante que os conhecimentos gerados pela IA sejam aplicados de maneira sensata e estratégica.

Em termos de limitações, este estudo foi baseado em uma base de dados específica e em entrevistas com um grupo limitado de profissionais do setor bancário. Portanto, futuras pesquisas podem ampliar o escopo, incluindo diferentes contextos geográficos e tipos de dados, bem como uma amostra mais ampla de participantes. Além disso, explorar o impacto da IA em outras áreas do setor financeiro, como investimentos e gestão de ativos, pode fornecer uma visão mais abrangente de seu potencial transformador. Adicionalmente, é essencial que futuras pesquisas desenvolvam e apresentem modelos de aprendizado de máquina com precisão superior a 90%, aumentando assim a eficácia e a confiabilidade das soluções propostas.

Por fim, pode-se afirmar que a aplicação da inteligência artificial no setor bancário é não apenas viável, mas altamente benéfica. A IA tem o potencial de revolucionar a tomada de decisão, proporcionando ganhos significativos em eficiência, precisão e inovação. No entanto, para maximizar esses benefícios, é essencial adotar uma abordagem equilibrada que combine a capacidade analítica da IA com a experiência e o julgamento humano. As instituições que conseguirem integrar esses elementos de forma harmoniosa estarão mais bem posicionadas para enfrentar os desafios e aproveitar as oportunidades do futuro digital.

## REFERÊNCIAS

AI HLEG, High Level Expert Group on Artificial Intelligence. **A Definition of AI - Main Capabilities and Disciplines**. Abril. 2019. Disponível em: <https://www.aepd.es/sites/default/files/2019-09/ai-definition.pdf>. Acesso em 16 nov. 2023.

ALI, Jehad. et al. **Random Forests and Decision Trees**. 2012. Disponível em: [https://www.researchgate.net/publication/259235118\\_Random\\_Forests\\_and\\_Decision\\_Trees](https://www.researchgate.net/publication/259235118_Random_Forests_and_Decision_Trees). Acesso em 27 nov. 2023.

AZEVEDO, Debora; MACHADO, Lisiane; SILVA, Lisiane Vasconcellos. **Métodos e Procedimentos de Pesquisa: do Projeto ao Relatório Final**. ed. Unisinos, Julho. 2011.

DAVIS, Nick. **Artificial Intelligence and Big Data: A Powerful Combination for Future Growth**. 2019. Disponível em: <https://www.su.org/blog/artificial-intelligence-and-big-data-a-powerful-combination-for-future-growth>. Acesso em 28 set. 2023.

DA SILVA, Ronaldo Angelo Dias. **Machine Learning para a Predição da Carga de Treinamento de um Atleta da Seleção Brasileira de Taekwondo**. Trabalho de pós Graduação da UFMG. 2023. Disponível em: <https://repositorio.ufmg.br/handle/1843/63397>. Acesso em 3 mar. 2024.

DOERR, Sebastian; GAMBACORTA, Leonardo; GARRALDA, José María Serena. Big Data and Machine Learning in Central Banking. **BIS Working Papers**, n. 930, 2021. Disponível em: <https://www.bis.org/publ/work930.htm>. Acesso em 8 set. 2023.

DONEPUDI, Praveen. Machine Learning and Artificial Intelligence in Banking. **Engineering International**, v. 5, n. 2, p. 83-86, 2017. Disponível em: [https://www.researchgate.net/publication/346323685\\_Machine\\_Learning\\_and\\_Artificial\\_Intelligence\\_in\\_Banking](https://www.researchgate.net/publication/346323685_Machine_Learning_and_Artificial_Intelligence_in_Banking). Acesso em 21 mar. 2024.

FONTANA, Eliton. **Introdução aos Algoritmos de Aprendizagem Supervisionada**. 2020. Disponível em: [https://fontana.paginas.ufsc.br/files/2018/03/apostila\\_ML.pdf](https://fontana.paginas.ufsc.br/files/2018/03/apostila_ML.pdf). Acesso em 07 mar. 2024.

FONSECA, Carlos Eduardo Correa da; MEIRELLES, Fernando de Souza; DINIZ, Eduardo Henrique. **Tecnologia Bancária no Brasil: Uma História de Conquistas, Uma Visão de Futuro**. FGV, RAE. 2010. Disponível em: <https://bibliotecadigital.fgv.br/dspace/handle/10438/13532>. Acesso em 8 nov. 2023.

GILL, Mohsin Asad et al. Cyber Attacks Detection Through Machine Learning in Banking. **Bulletin of Business and Economics** (BBE), v. 12, n. 2, p. 34–45, 2023. Disponível em: <https://bbejournal.com/index.php/BBE/article/view/443>. Acesso em 21 mar. 2024.

KAYA, Orçun. **Artificial Intelligence in Banking**. 2019. Disponível em: <https://www.scirp.org/reference/referencespapers?referenceid=3524382>. Acesso em 21 de março 2024.

KÖCHE, José Carlos. **Fundamentos de Metodologia Científica: Teoria da Ciência e Prática da Pesquisa**. ed. Petrópolis: Vozes, 2014.

MENDONÇA, Ana Waley. **Metodologia para Estudo de Caso**. 2014. Disponível em: <https://repositorio.animaeducacao.com.br/bitstream/ANIMA/21932/1/fulltext.pdf>. Acesso em 27 nov. 2023.

MENDONÇA, D.D.P. **Setor Bancário e Desenvolvimento Econômico: Um Estudo Sobre os Determinantes e a Evolução Recente do Crédito Bancário no Brasil**. 2006.

MOTA, Iolanda Margarida Lopes da. **Machine Learning na Previsão da Conversão de Clientes Alvos**. Tese de Doutorado. Instituto Superior de Economia e Gestão. 2022. Disponível em: <https://www.repository.utl.pt/bitstream/10400.5/27331/1/DM-IMLM-2022.pdf>. Acesso em 3 mar. 2024.

MURAKAMI, Milton. **Decisão Estratégica em TI: Estudo de Caso**. 2023. Disponível em: <https://www.teses.usp.br/teses/disponiveis/12/12139/tde-19112003-200926/es.php>. Acesso em 8 nov. 2023.

MULINARI, Rodrigo; BIAGINI, Sérgio. **Pesquisa FEBRABAN de Tecnologia Bancária 2023**. Volume 1. 2023. Disponível em: <https://cmsarquivos.febraban.org.br/Arquivos/documentos/PDF/Imprensa%20-Pesquisa%20Febraban%20de%20Tecnologia%20banc%C3%A1ria%20Volume%201.pdf>. Acesso em 28 set. 2023.

NAPPI, Joseli Fernanda. **Sistema bancário e regulação no Brasil: reflexões a partir da crise financeira internacional e da adequação à Basileia III**. Campinas, IE/UNICAMP: Dissertação de Mestrado, 2017. Disponível em: <http://repositorio.unicamp.br/Acervo/Detalhe/987893>. Acesso em 8 nov. 2023.

PARIS, Rohan. **Credit Score Classification**. 2022. Disponível em: <https://www.kaggle.com/datasets/parisrohan/credit-score-classification>. Acesso em 12 mar. 2024.

PASCHOARELLI, Luis Carlos; MEDOLA, Fausto Orsi; BONFIM, Gabriel Henrique Cruz. Características Qualitativas, Quantitativas de Abordagens Científicas: estudos de caso na subárea do Design Ergonômico. **Revista de Design, Tecnologia e Sociedade**, v. 2, n. 1, p. 65-78, 2015. Disponível em: <https://periodicos.unb.br/index.php/design-tecnologia-sociedade/article/download/15699/14030/26701>. Acesso em 18 mar. 2024.

PURI, Lakshkaushik Dattatraya. A Study of Applications of Artificial Intelligence in Banking and Finance Sector. **International Journal of Innovative Research in Science Engineering and Technology**, 2022. Disponível em: [https://www.researchgate.net/publication/360782923\\_A\\_STUDY\\_OF\\_APPLICATIONS\\_OF\\_ARTIFICIAL\\_INTELLIGENCE\\_IN\\_BANKING\\_AND\\_FINANCE\\_SECTOR](https://www.researchgate.net/publication/360782923_A_STUDY_OF_APPLICATIONS_OF_ARTIFICIAL_INTELLIGENCE_IN_BANKING_AND_FINANCE_SECTOR). Acesso em 17 nov. 2023.

RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning: Machine Learning and Deep Learning with Python, Scikit-Learn, and TensorFlow**. Birmingham (Uk): Packt Publishing, 2017.

REINSEL, David; GANTZ, John; RYDNING, John. Data Age 2025: **The Evolution of Data to Life-Critical**. SEAGATE. IDC (International Data Corporation). 2017. Disponível em: <https://www.seagate.com/files/www-content/our-story/trends/files/Seagate-WP-DataAge2025-March-2017.pdf>. Acesso em 28 set. 2023.

SHAWE-TAYLOR, John; SUN, Shiliang. A review of optimization methodologies in support vector machines. **Neurocomputing**, v. 74, n. 17, p. 3609-3618, 2021. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0925231211004371>. Acesso em 07 mar. 2024.

STELZER, Anna. **Predicting Credit Default Probabilities Using Machine Learning Techniques in The Face of Unequal Class Distributions**. 2019. Disponível em: <https://arxiv.org/pdf/1907.12996.pdf>. Acesso em 07 mar. 2024.

VASSALO, Daniel Humberto Cavalcante. **Análises de Competições Presentes na Plataforma Kaggle Para Auxiliar no Desenvolvimento de Novas Soluções para Problemas de Visão Computacional**. 2021. Disponível em: <https://www.repositorio.ufal.br/handle/123456789/10476>. Acesso em 29 nov. 2023.

VEDAPRADHA, R.; HARIHARAN, Ravi. **Application of Artificial Intelligence in Investment Banks**. 2018. Disponível em: [https://www.researchgate.net/publication/330567952\\_Application\\_of\\_Artificial\\_Intelligence\\_in\\_Investment\\_Banks](https://www.researchgate.net/publication/330567952_Application_of_Artificial_Intelligence_in_Investment_Banks). Acesso em 27 nov. 2023.

VIEIRA, Carlos André Marinho et al. Complexidade e Risco dos Conglomerados Financeiros Operantes no Brasil. **Revista Base (Administração e Contabilidade) da UNISINOS**, v. 17, n. 2. Dezembro. 2020. Disponível em: <https://www.redalyc.org/journal/3372/337264549007/html/>. Acesso em 30 set. 2023.

WIENER, Norbert. Some Moral and Technical Consequences of Automation. **Science**, v. 131, n. 3410, p. 1355–1358. Maio. 1960. Disponível em: <https://www.jstor.org/stable/1705998>. Acesso em 28 set. 2023.

## ANEXO A – ESTRUTURA DOS DADOS

Quadro 2 Detalhamento dos Dados

	Variáveis	Descrição
1	ID	Identificação única de uma entrada
2	Customer_ID	Identificação única de uma pessoa
3	Month	representa o mês do ano.
4	Name	O nome de uma pessoa.
5	Age	A idade da pessoa.
6	SSN	O número de seguro social de uma pessoa.
7	Occupation	A ocupação da pessoa.
8	Annual_Income	A renda anual da pessoa.
9	Monthly_Inhand_Salary	O salário mensal líquido de uma pessoa.
10	Num_Bank_Accounts	O número de contas bancárias que uma pessoa possui.
11	Num_Credit_Card	O número de outros cartões de crédito que uma pessoa possui.
12	Interest_Rate	A taxa de juros do cartão de crédito.
13	Num_of_Loan	O número de empréstimos feitos pelo banco.
14	Type_of_Loan	Os tipos de empréstimos feitos por uma pessoa.
15	Delay_from_due_date	O número médio de dias de atraso em relação à data de pagamento.
16	Num_of_Delayed_Payment	O número médio de pagamentos atrasados por uma pessoa.
17	Changed_Credit_Limit	A alteração percentual no limite do cartão de crédito.
18	Num_Credit_Inquiries	O número de consultas de crédito.
19	Credit_Mix	A classificação do mix de créditos.
20	Outstanding_Debt	A dívida restante a ser paga (em USD).
21	Credit_Utilization_Ratio	A proporção de utilização de crédito do cartão.
22	Credit_History_Age	A idade da história de crédito da pessoa.
23	Payment_of_Min_Amount	Se apenas o valor mínimo foi pago pela pessoa.
24	Total_EMI_per_month	Os pagamentos mensais de EMI (em USD).

25	<b>Amount_invested_monthly</b>	O valor investido mensalmente pelo cliente (em USD).
26	<b>Payment_Behaviour</b>	O comportamento de pagamento do cliente (em USD).
27	<b>Monthly_Balance</b>	O saldo mensal do cliente (em USD).
28	<b>Credit_Score</b>	A faixa de pontuação de crédito (Ruim, Regular, Bom).

Fonte: “*Credit score classification*” (Paris, 2022).

## APÊNDICE A – QUESTIONÁRIO DE ENTREVISTA

Figura 1 Questionário – Página 1

### Uso de Inteligência Artificial para Apoio à Tomada de Decisão em Instituições Bancárias.

Este questionário, totalmente anônimo, tem como objetivo coletar informações de especialistas do setor bancário que tomam decisões diariamente, a fim de avaliar a percepção e a experiência desses profissionais sobre o uso da inteligência artificial no processo de tomada de decisão em instituições bancárias. Buscando entender como a IA está sendo utilizada, os benefícios observados, os desafios enfrentados e as oportunidades futuras para melhorar a eficiência e a eficácia nas operações bancárias.

*Este questionário faz parte do Trabalho de Conclusão do Curso de Sistemas de Informação da Universidade Vale do Rio dos Sinos (UNISINOS).*

- **Aluno:** Raphael Benedeti
- **E-mail:** benedeti.rafael@gmail.com
- **Orientação:**  
Dr. Vinicius Costa de Souza

---

\* Indica uma pergunta obrigatória

1. **Idade \***

---

2. **Sexo \***

*Marcar apenas uma oval.*

- ☐ Masculino
- ☐ Feminino
- ☐ Prefiro não responder



## Figura 2 Questionário – Página 2

3. **Maior Formação Concluída \***

*Marcar apenas uma oval.*

- ☐ Ensino Fundamental
- ☐ Ensino Médio
- ☐ Ensino Técnico
- ☐ Ensino Superior
- ☐ Pós-Graduação (Especialização, MBA, etc.)
- ☐ Mestrado
- ☐ Doutorado

4. **Caso você tenha alguma formação de ensino superior, por favor informe o curso realizado: \***

---

5. **Há quanto tempo você trabalha no setor bancário? \***

*Marcar apenas uma oval.*

- ☐ Menos de 1 ano
- ☐ 1 a 3 anos
- ☐ 4 a 6 anos
- ☐ 7 a 10 anos
- ☐ 11 a 15 anos
- ☐ 16 a 20 anos
- ☐ Mais de 20 anos

6. **Em qual departamento ou área você atua dentro do banco? \***

---

Fonte: Elaborado pelo autor.

## Figura 3 Questionário – Página 3

7. **Que tipo de decisões você costuma tomar em sua função diariamente? \***

---

8. **Em sua função, suas decisões são principalmente baseadas em: \***

*Marcar apenas uma oval.*

- ☐ Programas de computador ou sistemas automatizados
- ☐ Minha experiência profissional e julgamento pessoal
- ☐ Uma combinação equilibrada de ambos

9. **Quais são as suas expectativas em relação ao uso de Inteligência Artificial para apoiar a tomada de decisões? \***

---

---

---

---

---

10. **Como você prevê que a implementação de Inteligência Artificial afetará a experiência do cliente nos serviços bancários? \***

---

---

---

---

---

11. **Em sua opinião, quais áreas dentro do setor bancário podem se beneficiar do uso de Inteligência Artificial para tomada de decisões? \***

---

## Figura 4 Questionário – Página 4

12. Qual é a sua opinião sobre tomar uma decisão com base em Inteligência Artificial que seja capaz de prever o score de crédito de um cliente? \*

Marcar apenas uma oval.

- ☐ Concordo totalmente - Acredito que pode ser uma ferramenta valiosa.
- ☐ Concordo - Vejo potencial nessa abordagem.
- ☐ Neutro - Estou indeciso(a) ou não tenho opinião formada sobre o assunto.
- ☐ Discordo - Tenho preocupações.
- ☐ Discordo totalmente - Tenho sérias preocupações sobre essa ideia.

13. Quais vantagens você enxerga em utilizar Inteligência Artificial para prever o score de crédito de um cliente? \*

---

---

---

---

---

14. Você acredita que a utilização de Inteligência Artificial pode melhorar a precisão na previsão do score de crédito de um cliente? Em comparação a métodos antigos? \*

Marcar apenas uma oval.

- ☐ Concordo totalmente - Acredito que a IA pode melhorar significativamente a precisão na previsão do score de crédito.
- ☐ Concordo - Vejo potencial na IA para melhorar a precisão, embora a eficácia dependa da qualidade dos dados e algoritmos.
- ☐ Neutro - Estou indeciso(a) ou não tenho opinião formada sobre o assunto.
- ☐ Discordo - Acredito que os métodos antigos ainda são mais confiáveis do que a IA para prever o score de crédito.
- ☐ Discordo totalmente - Não vejo benefícios na utilização da IA em comparação com métodos antigos.

## Figura 5 Questionário – Página 5

7. Que tipo de decisões você costuma tomar em sua função diariamente? \*

---

8. Em sua função, suas decisões são principalmente baseadas em: \*

*Marcar apenas uma oval.*

- ☐ Programas de computador ou sistemas automatizados
- ☐ Minha experiência profissional e julgamento pessoal
- ☐ Uma combinação equilibrada de ambos

9. Quais são as suas expectativas em relação ao uso de Inteligência Artificial para apoiar a tomada de decisões? \*

---

---

---

---

---

10. Como você prevê que a implementação de Inteligência Artificial afetará a experiência do cliente nos serviços bancários? \*

---

---

---

---

---

11. Em sua opinião, quais áreas dentro do setor bancário podem se beneficiar do uso de Inteligência Artificial para tomada de decisões? \*

---

## APÊNDICE B – INFORMAÇÕES DOS PARTICIPANTES

Quadro 3 Perfil dos Entrevistados


Entrevistado	Idade	Sexo	Maior formação concluída	Curso	Tempo no setor bancário
E1	55	F	Pós-Graduação (Especialização, MBA etc.)	Relações Públicas	Mais de 20 anos
E2	41	M	Mestrado	Mestrado em Gestão de Negócios	Mais de 20 anos
E3	34	M	Pós-Graduação (Especialização, MBA etc.)	Administração e Contabilidade	11 a 15 anos
E4	26	M	Ensino Superior	Engenharia de produção	4 a 6 anos
E5	30	F	Ensino Superior	Ciências Econômicas	1 a 3 anos
E6	25	M	Ensino Superior	Análise e desenvolvimento de sistemas	1 a 3 anos
E7	66	M	Ensino Superior	Administração	Mais de 20 anos
E8	32	M	Pós-Graduação (Especialização, MBA etc.)	Engenharia de computação	4 a 6 anos
E9	33	F	Ensino Superior	Administração	4 a 6 anos
E10	51	F	Mestrado	Administração	Mais de 20 anos
E11	39	M	Pós-Graduação (Especialização, MBA etc.)	Sistemas de Informação	7 a 10 anos
E12	52	F	Pós-Graduação (Especialização, MBA etc.)	Administração	16 a 20 anos
E13	61	F	Ensino Superior	Administração	Mais de 20 anos
E14	37	M	Pós-Graduação (Especialização, MBA etc.)	Ciências Econômicas	4 a 6 anos
E15	30	M	Ensino Superior	Ciência da Computação	7 a 10 anos

Fonte: Elaborado pelo autor.


## APÊNDICE C – DADOS DEMOGRÁFICOS DOS ENTREVISTADOS

Gráfico 1 Dados Demográficos dos Entrevistados


a) Sexo



b) Maior Formação Acadêmica



c) Cursos de Formação Acadêmica




Fonte: Elaborado pelo autor


## APÊNDICE D – CARACTERÍSTICAS DE ATUAÇÃO DOS PARTICIPANTES

Gráfico 2 Características de Atuação dos Participantes


### a) Setor de atuação



### b) Tempo de Experiência no Setor Bancário



### c) Critérios para Tomada de Decisão




Fonte: Elaborado pelo autor


## APÊNDICE E – PERCEPÇÕES E BENEFÍCIOS DA IA NO SETOR BANCÁRIO

Gráfico 3 Percepções, Setores Beneficiados e Expectativas sobre IA

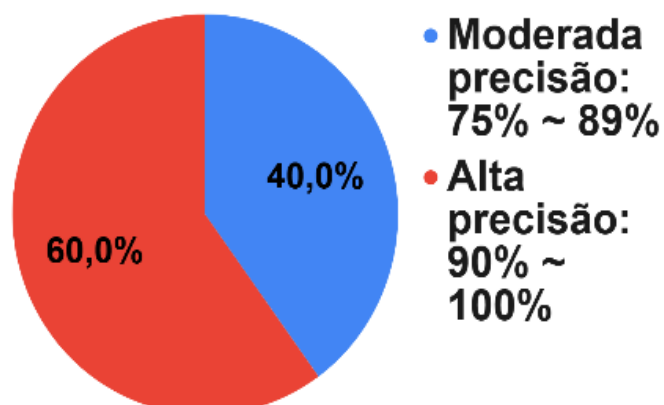
### a) Percepção sobre IA na Previsão de Score de Crédito



### b) Setores Bancários com Potencial de Benefício pela IA



### c) Expectativa de Precisão na IA



Fonte: Elaborado pelo autor